

# Des différences F/H significatives ? Introduction aux tests statistiques !

Tiffany Cherchi

Mars 2022

Women's day ... is not enough

**Pré-requis : Vocabulaire en statistiques**

Test statistique : comparaison de deux proportions

Test d'indépendance : de deux caractéristiques

Conclusions

# Un peu de vocabulaire statistique


Population

Ensemble  
exhaustif

Paramètre  
théorique  $\theta^*$


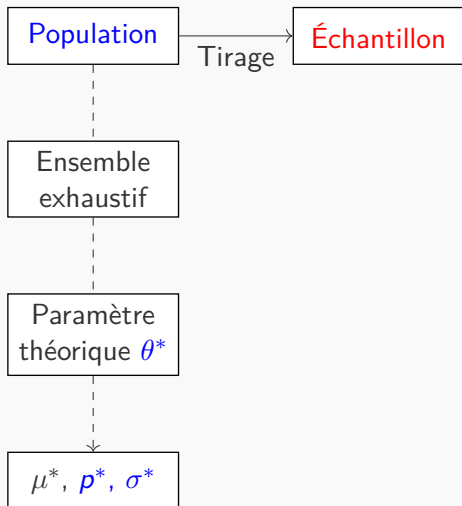
$\mu^*, p^*, \sigma^*$

Population


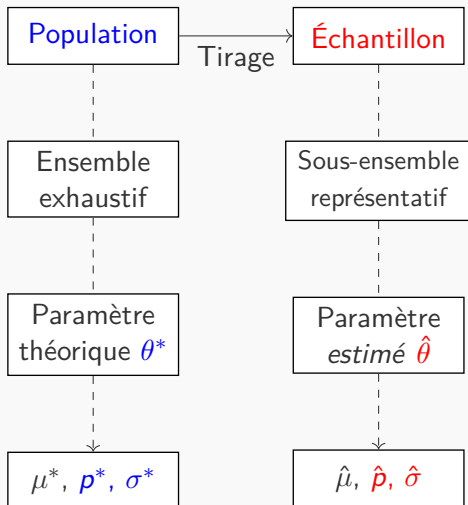


Sample


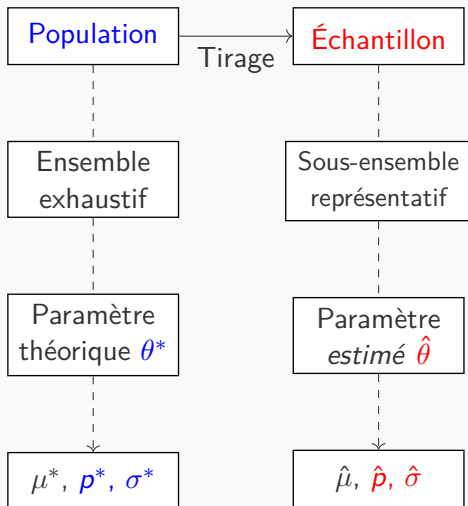
# Un peu de vocabulaire statistique



# Un peu de vocabulaire statistique




# Un peu de vocabulaire statistique




# Qualités d'un estimateur

Faible biais




# Qualités d'un estimateur

Faible biais




Fort biais







# Qualités d'un estimateur




# Qualités d'un estimateur



# Qualités d'un estimateur




# Qualités d'un estimateur



Des estimateurs sans biais :

► moyenne :  $\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i$


# Qualités d'un estimateur



Des estimateurs sans biais :

- ▶ moyenne :  $\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i$
- ▶ proportion :  $\hat{p} = \frac{\#succes}{n}$

# Qualités d'un estimateur




Des estimateurs sans biais :

- ▶ moyenne :  $\hat{\mu} = \frac{1}{n} \sum_1^n x_i$
- ▶ proportion :  $\hat{p} = \frac{\#succes}{n}$
- ▶ variance (corrigée) :

$$\hat{\sigma}^2 = \frac{\sum_1^n (x_i - \hat{\mu})^2}{n - 1}$$

# Qualités d'un estimateur



Des estimateurs sans biais :

- ▶ moyenne :  $\hat{\mu} = \frac{1}{n} \sum_1^n x_i$
- ▶ proportion :  $\hat{p} = \frac{\#succes}{n}$
- ▶ variance (corrigée) :

$$\hat{\sigma}^2 = \frac{\sum_1^n (x_i - \hat{\mu})^2}{n - 1}$$

Un estimateur biaisé

- ▶ variance :

$$\hat{s}^2 = \frac{\sum_1^n (x_i - \hat{\mu})^2}{n}$$

# Données binaires : estimer une proportion

Pour un échantillon de  $n$  données, de valeurs 0 (échec) ou 1 (succès) :



# Données binaires : estimer une proportion

Pour un échantillon de  $n$  données, de valeurs 0 (échec) ou 1 (succès) :

- ▶ un estimateur de la proportion de succès est :  $\hat{p} = \frac{\#succes}{n} \in [0, 1]$ ,

# Données binaires : estimer une proportion


Pour un échantillon de  $n$  données, de valeurs 0 (échec) ou 1 (succès) :

- ▶ un estimateur de la proportion de succès est :  $\hat{p} = \frac{\#succes}{n} \in [0, 1]$ ,
- ▶ la variance (de l'estimateur) est :  $\hat{\sigma}^2 = \frac{p \times (1-p)}{n}$ ,

# Données binaires : estimer une proportion

Pour un échantillon de  $n$  données, de valeurs 0 (échec) ou 1 (succès) :


- ▶ un estimateur de la proportion de succès est :  $\hat{p} = \frac{\#succes}{n} \in [0, 1]$ ,
- ▶ la variance (de l'estimateur) est :  $\hat{\sigma}^2 = \frac{p \times (1-p)}{n}$ ,



# Données binaires : estimer une proportion

Pour un échantillon de  $n$  données, de valeurs 0 (échec) ou 1 (succès) :

- ▶ un estimateur de la proportion de succès est :  $\hat{p} = \frac{\#succes}{n} \in [0, 1]$ ,
- ▶ la variance (de l'estimateur) est :  $\hat{\sigma}^2 = \frac{p \times (1-p)}{n}$ ,




$$\hat{p} = \frac{1}{2}, \hat{\sigma} = \sqrt{\frac{0.5 \times (1-0.5)}{4}} = 0.25.$$

$$\hat{p} = \frac{1}{2}, \hat{\sigma} = \sqrt{\frac{0.5 \times (1-0.5)}{36}} \approx 0,08.$$

# Données binaires : estimer une proportion

Pour un échantillon de  $n$  données, de valeurs 0 (échec) ou 1 (succès) :

- ▶ un estimateur de la proportion de succès est :  $\hat{p} = \frac{\#succes}{n} \in [0, 1]$ ,
- ▶ la variance (de l'estimateur) est :  $\hat{\sigma}^2 = \frac{p \times (1-p)}{n}$ ,



$$\hat{p} = \frac{1}{2}, \hat{\sigma} = \sqrt{\frac{0.5 \times (1-0.5)}{4}} = 0.25.$$


$$\hat{p} = \frac{1}{2}, \hat{\sigma} = \sqrt{\frac{0.5 \times (1-0.5)}{36}} \approx 0,08.$$

$$\hat{p} = \frac{1}{3}, \hat{\sigma} = \sqrt{\frac{0.33 \times (1-0.33)}{3}} \approx 0,27.$$

# Données binaires : estimer une proportion

Pour un échantillon de  $n$  données, de valeurs 0 (échec) ou 1 (succès) :

- ▶ un estimateur de la proportion de succès est :  $\hat{p} = \frac{\#succes}{n} \in [0, 1]$ ,
- ▶ la variance (de l'estimateur) est :  $\hat{\sigma}^2 = \frac{p \times (1-p)}{n}$ ,



$$\hat{p} = \frac{1}{2}, \hat{\sigma} \approx 0,079.$$


$$\hat{p} = \frac{1}{2}, \hat{\sigma} \approx 0,026.$$

$$\hat{p} = \frac{1}{3}, \hat{\sigma} \approx 0,086.$$

## Données binaires : estimer une proportion

Pour un échantillon de  $n$  données, de valeurs 0 (échec) ou 1 (succès) :

- ▶ un estimateur de la proportion de succès est :  $\hat{p} = \frac{\#succes}{n} \in [0, 1]$ ,
- ▶ la variance (de l'estimateur) est :  $\hat{\sigma}^2 = \frac{p \times (1-p)}{n}$ ,
- ▶ un IC\* à 95% pour  $\hat{p}$  est :  $[\hat{p} \pm 1.96 \times \hat{\sigma}]$ .



$$\hat{p} = \frac{1}{2}, \hat{\sigma} \approx 0,079, IC_{95}(\hat{p}) = [0.35; 0.65].$$

$$\hat{p} = \frac{1}{2}, \hat{\sigma} \approx 0,026, IC_{95}(\hat{p}) = [0.45; 0.55].$$

$$\hat{p} = \frac{1}{3}, \hat{\sigma} \approx 0,086, IC_{95}(\hat{p}) = [0.16; 0.50].$$

$$* n \geq 30, n\hat{p} \geq 5, n(1 - \hat{p}) \geq 5.$$

Pré-requis : Vocabulaire en statistiques

**Test statistique : comparaison de deux proportions**

Test d'indépendance : de deux caractéristiques

Conclusions



# Test d'hypothèse : comparer une proportion à une référence

Contexte : comparer une **proportion estimée  $\hat{p}$**  sur un  $n$ -échantillon, avec une **proportion de référence  $p_0$** .

## Test d'hypothèse : comparer une proportion à une référence

Contexte : comparer une **proportion estimée  $\hat{p}$**  sur un  $n$ -échantillon, avec une **proportion de référence  $p_0$** .

Exemple : Depuis la réforme du lycée, la **part de filles**, parmi les élèves de maths, est elle significativement différente de **la parité,  $p_0 = 50\%$**  ?

## Test d'hypothèse : comparer une proportion à une référence

Contexte : comparer une **proportion estimée  $\hat{p}$**  sur un  $n$ -échantillon, avec une **proportion de référence  $p_0$** .

Exemple : Depuis la réforme du lycée, la **part de filles**, parmi les élèves de maths, est elle significativement différente de **la parité,  $p_0 = 50\%$**  ?

Hypothèses :  $\mathcal{H}_0 : p_0 = \hat{p}$  contre  $\mathcal{H}_1 : p_0 \neq \hat{p}$ .

# Test d'hypothèse : comparer une proportion à une référence

Contexte : comparer une **proportion estimée**  $\hat{p}$  sur un  $n$ -échantillon, avec une **proportion de référence**  $p_0$ .

Exemple : Depuis la réforme du lycée, la **part de filles**, parmi les élèves de maths, est elle significativement différente de **la parité**,  $p_0 = 50\%$  ?

Hypothèses :  $\mathcal{H}_0 : p_0 = \hat{p}$  contre  $\mathcal{H}_1 : p_0 \neq \hat{p}$ .

Statistique de test :  $\hat{z} = \frac{p_0 - \hat{p}}{\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}} \sim \mathcal{N}(0, 1)$  sous l'hypothèse  $\mathcal{H}_0$ .

## Test d'hypothèse : comparer une proportion à une référence


Contexte : comparer une **proportion estimée**  $\hat{p}$  sur un  $n$ -échantillon, avec une **proportion de référence**  $p_0$ .

Exemple : Depuis la réforme du lycée, la **part de filles**, parmi les élèves de maths, est elle significativement différente de **la parité**,  $p_0 = 50\%$  ?

Hypothèses :  $\mathcal{H}_0 : p_0 = \hat{p}$  contre  $\mathcal{H}_1 : p_0 \neq \hat{p}$ .

Statistique de test :  $\hat{z} = \frac{p_0 - \hat{p}}{\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}} \sim \mathcal{N}(0, 1)$  sous l'hypothèse  $\mathcal{H}_0$ .

Conclusion : au risque  $\alpha \in [0, 1]$ ,  $\exists ! t_\alpha > 0$  tq  $P(-t_\alpha \leq \hat{z} \leq t_\alpha) = 1 - \alpha$ .  
On rejette  $\mathcal{H}_0$  si  $\hat{z} < -t_\alpha$  ou  $\hat{z} > t_\alpha$ .



# Test d'hypothèse : comparer une proportion à une référence


Contexte : comparer une **proportion estimée**  $\hat{p}$  sur un  $n$ -échantillon, avec une **proportion de référence**  $p_0$ .

Exemple : Depuis la réforme du lycée, la **part de filles**, parmi les élèves de maths, est elle significativement différente de **la parité**,  $p_0 = 50\%$  ?

Hypothèses :  $\mathcal{H}_0 : p_0 = \hat{p}$  contre  $\mathcal{H}_1 : p_0 \neq \hat{p}$ .

Statistique de test :  $\hat{z} = \frac{p_0 - \hat{p}}{\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}} \sim \mathcal{N}(0, 1)$  sous l'hypothèse  $\mathcal{H}_0$ .

Conclusion : au risque  $\alpha \in [0, 1]$ ,  $\exists ! t_\alpha > 0$  tq  $P(-t_\alpha \leq \hat{z} \leq t_\alpha) = 1 - \alpha$ .  
On rejette  $\mathcal{H}_0$  si  $\hat{z} < -t_\alpha$  ou  $\hat{z} > t_\alpha$ .



## Exemples (1) : part des filles en maths au lycée

Sur les 149540 élèves qui ont choisi les mathématiques comme spécialité au baccalauréat 2021, 62390 sont des filles. [source]

## Exemples (1) : part des filles en maths au lycée

Sur les 149540 élèves qui ont choisi les mathématiques comme spécialité au baccalauréat 2021, 62390 sont des filles. [source]

Proportion : estimation de la part de filles parmi les élèves de maths :

$$\hat{p} = \frac{62390}{149540} \approx 0,417 \text{ avec } IC_{95}(\hat{p}) \approx [0.414; 0.419].$$



## Exemples (1) : part des filles en maths au lycée

Sur les 149540 élèves qui ont choisi les mathématiques comme spécialité au baccalauréat 2021, 62390 sont des filles. [source]

Proportion : estimation de la part de filles parmi les élèves de maths :

$$\hat{p} = \frac{62390}{149540} \approx 0,417 \text{ avec } IC_{95}(\hat{p}) \approx [0.414; 0.419].$$

Statistique de test :  $\hat{z} = \frac{p_0 - \hat{p}}{\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}} \approx 65.$

## Exemples (1) : part des filles en maths au lycée

Sur les 149540 élèves qui ont choisi les mathématiques comme spécialité au baccalauréat 2021, 62390 sont des filles. [source]

Proportion : estimation de la part de filles parmi les élèves de maths :

$$\hat{p} = \frac{62390}{149540} \approx 0,417 \text{ avec } IC_{95}(\hat{p}) \approx [0.414; 0.419].$$

Statistique de test :  $\hat{z} = \frac{p_0 - \hat{p}}{\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}} \approx 65.$

Conclusion : au risque  $\alpha = 5\%$ , on a  $t_\alpha = 1.96$ , et ici **on rejette**  $\mathcal{H}_0$ .

## Exemples (1) : part des filles en maths au lycée


Sur les 149540 élèves qui ont choisi les mathématiques comme spécialité au baccalauréat 2021, 62390 sont des filles. [source]

Proportion : estimation de la part de filles parmi les élèves de maths :

$$\hat{p} = \frac{62390}{149540} \approx 0,417 \text{ avec } IC_{95}(\hat{p}) \approx [0.414; 0.419].$$

Statistique de test :  $\hat{z} = \frac{p_0 - \hat{p}}{\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}} \approx 65.$

Conclusion : au risque  $\alpha = 5\%$ , on a  $t_\alpha = 1.96$ , et ici **on rejette**  $\mathcal{H}_0$ .



## Exemples (1) : part des filles en maths au lycée


Sur les 149540 élèves qui ont choisi les mathématiques comme spécialité au baccalauréat 2021, 62390 sont des filles. [source]

Proportion : estimation de la part de filles parmi les élèves de maths :

$$\hat{p} = \frac{62390}{149540} \approx 0,417 \text{ avec } IC_{95}(\hat{p}) \approx [0.414; 0.419].$$

Statistique de test :  $\hat{z} = \frac{p_0 - \hat{p}}{\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}} \approx 65$ .

Conclusion : au risque  $\alpha = 5\%$ , on a  $t_\alpha = 1.96$ , et ici **on rejette**  $\mathcal{H}_0$ .



## Exemples (2) : part des femmes (MCF) en section 26

Sur les 1147 MCF en section 26, 387 sont des femmes. [source]

Proportion : estimation de la part des femmes :

$$\hat{p} = \frac{387}{1147} \approx 0,34 \text{ avec } IC_{95}(\hat{p}) \approx [0.31; 0.37].$$

Statistique de test :  $\hat{z} = \frac{p_0 - \hat{p}}{\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}} \approx 11.$

## Exemples (2) : part des femmes (MCF) en section 26

Sur les 1147 MCF en section 26, 387 sont des femmes. [source]

Proportion : estimation de la part des femmes :

$$\hat{p} = \frac{387}{1147} \approx 0,34 \text{ avec } IC_{95}(\hat{p}) \approx [0.31; 0.37].$$

Statistique de test :  $\hat{z} = \frac{p_0 - \hat{p}}{\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}} \approx 11.$

Conclusion : au risque  $\alpha = 5\%$ , on a  $t_\alpha = 1.96$ , et ici **on rejette**  $\mathcal{H}_0$ .

## Exemples (2) : part des femmes (MCF) en section 26


Sur les 1147 MCF en section 26, 387 sont des femmes. [source]

Proportion : estimation de la part des femmes :

$$\hat{p} = \frac{387}{1147} \approx 0,34 \text{ avec } IC_{95}(\hat{p}) \approx [0.31; 0.37].$$

Statistique de test :  $\hat{z} = \frac{p_0 - \hat{p}}{\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}} \approx 11.$

Conclusion : au risque  $\alpha = 5\%$ , on a  $t_\alpha = 1.96$ , et ici **on rejette**  $\mathcal{H}_0$ .



## Exemples (2) : part des femmes (MCF) en section 26


Sur les 1147 MCF en section 26, 387 sont des femmes. [source]

Proportion : estimation de la part des femmes :

$$\hat{p} = \frac{387}{1147} \approx 0,34 \text{ avec } IC_{95}(\hat{p}) \approx [0.31; 0.37].$$

Statistique de test :  $\hat{z} = \frac{p_0 - \hat{p}}{\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}} \approx 11.$

Conclusion : au risque  $\alpha = 5\%$ , on a  $t_\alpha = 1.96$ , et ici **on rejette**  $\mathcal{H}_0$ .



Si  $n=1147$ , il faudrait 541 femmes, soit  $\hat{p}=0.471$  pour ne pas rejeter  $\mathcal{H}_0$ .



## Exemples (3) : part des femmes (PR) en section 26

Sur les 629 MCF en section 25, 101 sont des femmes. [source]

Proportion : estimation de la part des femmes :

$$\hat{p} = \frac{101}{629} \approx 0,16 \text{ avec } IC_{95}(\hat{p}) \approx [0.13; 0.19].$$

Statistique de test :  $\hat{z} = \frac{p_0 - \hat{p}}{\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}} \approx 23.$

## Exemples (3) : part des femmes (PR) en section 26

Sur les 629 MCF en section 25, 101 sont des femmes. [source]

Proportion : estimation de la part des femmes :

$$\hat{p} = \frac{101}{629} \approx 0,16 \text{ avec } IC_{95}(\hat{p}) \approx [0.13; 0.19].$$

Statistique de test :  $\hat{z} = \frac{p_0 - \hat{p}}{\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}} \approx 23.$

Conclusion : au risque  $\alpha = 5\%$ , on a  $t_\alpha = 1.96$ , et ici **on rejette**  $\mathcal{H}_0$ .

## Exemples (3) : part des femmes (PR) en section 26


Sur les 629 MCF en section 25, 101 sont des femmes. [source]

Proportion : estimation de la part des femmes :

$$\hat{p} = \frac{101}{629} \approx 0,16 \text{ avec } IC_{95}(\hat{p}) \approx [0.13; 0.19].$$

Statistique de test :  $\hat{z} = \frac{p_0 - \hat{p}}{\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}} \approx 23$ .

Conclusion : au risque  $\alpha = 5\%$ , on a  $t_\alpha = 1.96$ , et ici **on rejette**  $\mathcal{H}_0$ .



## Exemples (3) : part des femmes (PR) en section 26


Sur les 629 MCF en section 25, 101 sont des femmes. [source]

Proportion : estimation de la part des femmes :

$$\hat{p} = \frac{101}{629} \approx 0,16 \text{ avec } IC_{95}(\hat{p}) \approx [0.13; 0.19].$$

Statistique de test :  $\hat{z} = \frac{p_0 - \hat{p}}{\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}} \approx 23$ .

Conclusion : au risque  $\alpha = 5\%$ , on a  $t_\alpha = 1.96$ , et ici **on rejette**  $\mathcal{H}_0$ .



Si  $n=629$ , il faudrait 290 femmes, soit  $\hat{p} = 0.461$  pour ne pas rejeter  $\mathcal{H}_0$ .

## Exemples (4) : part des femmes (MCF) en section 25

Sur les 823 MCF en section 25, 155 sont des femmes. [source]

Proportion : estimation de la part des femmes :

$$\hat{p} = \frac{155}{823} \approx 0,188 \text{ avec } IC_{95}(\hat{p}) \approx [0.162; 0.215].$$

Statistique de test :  $\hat{z} = \frac{p_0 - \hat{p}}{\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}} \approx 23.$

## Exemples (4) : part des femmes (MCF) en section 25

Sur les 823 MCF en section 25, 155 sont des femmes. [source]

Proportion : estimation de la part des femmes :

$$\hat{p} = \frac{155}{823} \approx 0,188 \text{ avec } IC_{95}(\hat{p}) \approx [0.162; 0.215].$$

Statistique de test :  $\hat{z} = \frac{p_0 - \hat{p}}{\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}} \approx 23.$

Conclusion : au risque  $\alpha = 5\%$ , on a  $t_\alpha = 1.96$ , et ici **on rejette**  $\mathcal{H}_0$ .

## Exemples (4) : part des femmes (MCF) en section 25


Sur les 823 MCF en section 25, 155 sont des femmes. [source]

Proportion : estimation de la part des femmes :

$$\hat{p} = \frac{155}{823} \approx 0,188 \text{ avec } IC_{95}(\hat{p}) \approx [0.162; 0.215].$$

Statistique de test :  $\hat{z} = \frac{p_0 - \hat{p}}{\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}} \approx 23$ .

Conclusion : au risque  $\alpha = 5\%$ , on a  $t_\alpha = 1.96$ , et ici **on rejette**  $\mathcal{H}_0$ .



## Exemples (4) : part des femmes (MCF) en section 25


Sur les 823 MCF en section 25, 155 sont des femmes. [source]

Proportion : estimation de la part des femmes :

$$\hat{p} = \frac{155}{823} \approx 0,188 \text{ avec } IC_{95}(\hat{p}) \approx [0.162; 0.215].$$

Statistique de test :  $\hat{z} = \frac{p_0 - \hat{p}}{\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}} \approx 23.$

Conclusion : au risque  $\alpha = 5\%$ , on a  $t_\alpha = 1.96$ , et ici **on rejette**  $\mathcal{H}_0$ .



Si  $n=823$ , il faudrait 383 femmes, soit  $\hat{p} = 0.466$  pour ne pas rejeter  $\mathcal{H}_0$ .



## Exemples (5) : part des femmes (PR) en section 25

Sur les 498 PR en section 25, 31 sont des femmes. [source]

Proportion : estimation de la part des femmes :

$$\hat{p} = \frac{31}{498} \approx 0,06 \text{ avec } IC_{95}(\hat{p}) \approx [0.04; 0.08].$$

Statistique de test :  $\hat{z} = \frac{p_0 - \hat{p}}{\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}} \approx 40.$

## Exemples (5) : part des femmes (PR) en section 25

Sur les 498 PR en section 25, 31 sont des femmes. [source]

Proportion : estimation de la part des femmes :

$$\hat{p} = \frac{31}{498} \approx 0,06 \text{ avec } IC_{95}(\hat{p}) \approx [0.04; 0.08].$$

Statistique de test :  $\hat{z} = \frac{p_0 - \hat{p}}{\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}} \approx 40.$

Conclusion : au risque  $\alpha = 5\%$ , on a  $t_\alpha = 1.96$ , et ici **on rejette**  $\mathcal{H}_0$ .

## Exemples (5) : part des femmes (PR) en section 25


Sur les 498 PR en section 25, 31 sont des femmes. [source]

Proportion : estimation de la part des femmes :

$$\hat{p} = \frac{31}{498} \approx 0,06 \text{ avec } IC_{95}(\hat{p}) \approx [0.04; 0.08].$$

Statistique de test :  $\hat{z} = \frac{p_0 - \hat{p}}{\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}} \approx 40.$

Conclusion : au risque  $\alpha = 5\%$ , on a  $t_\alpha = 1.96$ , et ici **on rejette**  $\mathcal{H}_0$ .



## Exemples (5) : part des femmes (PR) en section 25


Sur les 498 PR en section 25, 31 sont des femmes. [source]

Proportion : estimation de la part des femmes :

$$\hat{p} = \frac{31}{498} \approx 0,06 \text{ avec } IC_{95}(\hat{p}) \approx [0.04; 0.08].$$

Statistique de test :  $\hat{z} = \frac{p_0 - \hat{p}}{\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}} \approx 40$ .

Conclusion : au risque  $\alpha = 5\%$ , on a  $t_\alpha = 1.96$ , et ici **on rejette**  $\mathcal{H}_0$ .



Si  $n=498$ , il faudrait 228 femmes, soit  $\hat{p} = 0.457$  pour ne pas rejeter  $\mathcal{H}_0$ .

Pré-requis : Vocabulaire en statistiques

Test statistique : comparaison de deux proportions

Test d'indépendance : de deux caractéristiques

Conclusions

# Test d'indépendance de deux variables

Contexte : comparer des effectifs observés de deux caractéristiques  $X$  et  $Y$ , avec des effectifs théoriques issus de variables indépendantes.

# Test d'indépendance de deux variables

Contexte : comparer des **effectifs observés** de deux caractéristiques  $X$  et  $Y$ , avec des **effectifs théoriques issus de variables indépendantes**.

Exemple : On note  $X$  la v.a *genre* et  $Y$  la v.a *faire des maths au lycée*.

$O_{ij}$	F	G	total
maths	62 390	87 150	149 540
maths	147 663	74 502	222 165
total	210 053	161 652	371 705

# Test d'indépendance de deux variables

Contexte : comparer des **effectifs observés** de deux caractéristiques  $X$  et  $Y$ , avec des **effectifs théoriques issus de variables indépendantes**.

Exemple : On note  $X$  la v.a *genre* et  $Y$  la v.a *faire des maths au lycée*.

$O_{ij}$	F	G	total
maths	62 390	87 150	149 540
maths	147 663	74 502	222 165
total	210 053	161 652	371 705

$$T_{ij} = \frac{(O_{i+} \times O_{+j})}{n}$$

$$O_{i+} = \sum_j^n O_{ij}$$

$$O_{+j} = \sum_i O_{ij}$$



# Test d'indépendance de deux variables

Contexte : comparer des **effectifs observés** de deux caractéristiques  $X$  et  $Y$ , avec des **effectifs théoriques** issus de variables indépendantes.

Exemple : On note  $X$  la v.a *genre* et  $Y$  la v.a *faire des maths au lycée*.

$O_{ij}$	F	G	total
maths	62 390	87 150	149 540
maths	147 663	74 502	222 165
total	210 053	161 652	371 705

$$T_{ij} = \frac{(O_{i+} \times O_{+j})}{n}$$

$$O_{i+} = \sum_j O_{ij}$$

$$O_{+j} = \sum_i O_{ij}$$

$T_{ij}$	F	G	total
maths	84 506	65 034	149 540
maths	125 547	96 618	222 165
total	210 053	161 652	371 705

# Test d'indépendance de deux variables

Contexte : comparer des **effectifs observés** de deux caractéristiques  $X$  et  $Y$ , avec des **effectifs théoriques issus de variables indépendantes**.

Exemple : On note  $X$  la v.a *genre* et  $Y$  la v.a *faire des maths au lycée*.

$O_{ij}$	F	G	total
maths	62 390	87 150	149 540
<del>maths</del>	147 663	74 502	222 165
total	210 053	161 652	371 705

$$T_{ij} = \frac{(O_{i+} \times O_{+j})}{n}$$

$$O_{i+} = \sum_j O_{ij}$$

$$O_{+j} = \sum_i O_{ij}$$

$T_{ij}$	F	G	total
maths	84 506	65 034	149 540
<del>maths</del>	125 547	96 618	222 165
total	210 053	161 652	371 705

Hypothèses :  $\mathcal{H}_0 : X \perp\!\!\!\perp Y$  vs  $\mathcal{H}_1 : X \not\perp\!\!\!\perp Y$ ,  $\hat{z} = \sum_{i,j} \frac{(O_{i,j} - T_{i,j})^2}{T_{i,j}} \sim \chi_1^2$  sous  $\mathcal{H}_0$ .

# Test d'indépendance de deux variables

Contexte : comparer des **effectifs observés** de deux caractéristiques  $X$  et  $Y$ , avec des **effectifs théoriques issus de variables indépendantes**.

Exemple : On note  $X$  la v.a *genre* et  $Y$  la v.a *faire des maths au lycée*.

$O_{ij}$	F	G	total
maths	62 390	87 150	149 540
maths	147 663	74 502	222 165
total	210 053	161 652	371 705

$$T_{ij} = \frac{(O_{i+} \times O_{+j})}{n}$$

$$O_{i+} = \sum_j O_{ij}$$

$$O_{+j} = \sum_i O_{ij}$$

$T_{ij}$	F	G	total
maths	84 506	65 034	149 540
maths	125 547	96 618	222 165
total	210 053	161 652	371 705

Hypothèses :  $\mathcal{H}_0 : X \perp\!\!\!\perp Y$  vs  $\mathcal{H}_1 : X \not\perp\!\!\!\perp Y$ ,  $\hat{z} = \sum_{i,j} \frac{(O_{i,j} - T_{i,j})^2}{T_{i,j}} \sim \chi_1^2$  sous  $\mathcal{H}_0$ .

Conclusion : au risque  $\alpha=5\%$ , on rejette  $\mathcal{H}_0$  si  $\hat{z} > t_\alpha = 3.84$ .

# Test d'indépendance de deux variables

Contexte : comparer des **effectifs observés** de deux caractéristiques  $X$  et  $Y$ , avec des **effectifs théoriques** issus de variables indépendantes.

Exemple : On note  $X$  la v.a *genre* et  $Y$  la v.a *faire des maths au lycée*.

$O_{ij}$	F	G	total
maths	62 390	87 150	149 540
maths	147 663	74 502	222 165
total	210 053	161 652	371 705

$$T_{ij} = \frac{(O_{i+} \times O_{+j})}{n}$$


$$O_{i+} = \sum_j O_{ij}$$

$$O_{+j} = \sum_i O_{ij}$$

$T_{ij}$	F	G	total
maths	84 506	65 034	149 540
maths	125 547	96 618	222 165
total	210 053	161 652	371 705

Hypothèses :  $\mathcal{H}_0 : X \perp\!\!\!\perp Y$  vs  $\mathcal{H}_1 : X \not\perp\!\!\!\perp Y$ ,  $\hat{z} = \sum_{i,j} \frac{(O_{i,j} - T_{i,j})^2}{T_{i,j}} \sim \chi_1^2$  sous  $\mathcal{H}_0$ .

Conclusion : au risque  $\alpha=5\%$ , on rejette  $\mathcal{H}_0$  si  $\hat{z} > t_\alpha = 3.84$ . Ici,  $\hat{z} = 22266$ .



# Test d'indépendance de deux variables

Contexte : comparer des **effectifs observés** de deux caractéristiques  $X$  et  $Y$ , avec des **effectifs théoriques issus de variables indépendantes**.

Exemple : On note  $X$  la v.a *genre* et  $Y$  la v.a *faire des maths au lycée*.

$O_{ij}$	F	G	total
maths	62 390	87 150	149 540
maths	147 663	74 502	222 165
total	210 053	161 652	371 705

$$T_{ij} = \frac{(O_{i+} \times O_{+j})}{O_{++}}$$


$$O_{i+} = \sum_j O_{ij}$$

$$O_{+j} = \sum_i O_{ij}$$

$T_{ij}$	F	G	total
maths	84 506	65 034	149 540
maths	125 547	96 618	222 165
total	210 053	161 652	371 705

Hypothèses :  $\mathcal{H}_0 : X \perp\!\!\!\perp Y$  vs  $\mathcal{H}_1 : X \not\perp\!\!\!\perp Y$ ,  $\hat{z} = \sum_{i,j} \frac{(O_{i,j} - T_{i,j})^2}{T_{i,j}} \sim \chi_1^2$  sous  $\mathcal{H}_0$ .

Conclusion : au risque  $\alpha=5\%$ , on rejette  $\mathcal{H}_0$  si  $\hat{z} > t_\alpha = 3.84$ . Ici,  $\hat{z} = 22266$ .



**Pré-requis : Vocabulaire en statistiques**

**Test statistique : comparaison de deux proportions**

**Test d'indépendance : de deux caractéristiques**

**Conclusions**

## Quelques ressources

- ▶ chiffres filles et maths au lycée :  
[test]<https://femmes-et-maths.fr/2022/03/17/30-des-filles-et-54-des-garcons-ont-presente-la-specialite-maths-au-baccalaureat-2021/>
- ▶ chiffres femmes et maths (MCF & PR 25, 26) :  
<https://femmes-et-maths.fr/wp-content/uploads/2020/02/journéeParité4BR0ZE.pdf>
- ▶ Pour un regard objectif/quantifié sur les stéréotypes :  
[https://femmes-et-maths.fr/wp-content/uploads/2021/03/Brochure\\_Grand\\_Public\\_interactif.pdf](https://femmes-et-maths.fr/wp-content/uploads/2021/03/Brochure_Grand_Public_interactif.pdf)